

Soft Actor Critic

Oliver Chmurzynski, Leon Bütinghaus, Thilo Röthemeyer

22. April 2021

Inhaltsverzeichnis

1 Soft Actor-Critic Grundlagen

- Motivation
- Soft Policy Iteration

2 Soft Actor-Critic im kontinuierlichen Raum

- SAC Grundprinzip
- SAC Update Regeln
- Algorithmus

3 Ergebnisse

- Vergleich mit anderen Algorithmen
- Zusammenfassung

4 Literaturverzeichnis

Inhaltsverzeichnis

1 Soft Actor-Critic Grundlagen

- Motivation
- Soft Policy Iteration

2 Soft Actor-Critic im kontinuierlichen Raum

- SAC Grundprinzip
- SAC Update Regeln
- Algorithmus

3 Ergebnisse

- Vergleich mit anderen Algorithmen
- Zusammenfassung

4 Literaturverzeichnis

Einordnung

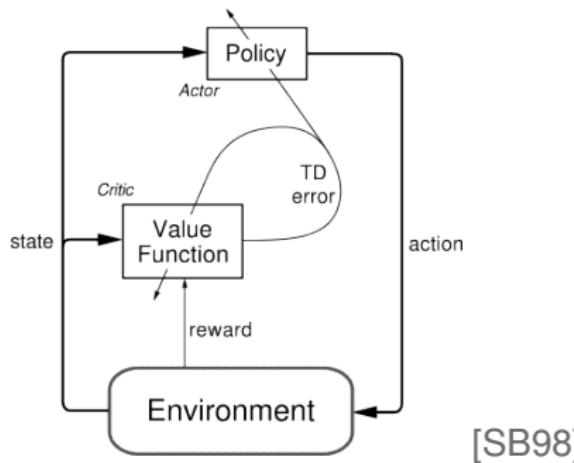
- Soft Actor-Critic ist ein off-policy reinforcement learning Algorithmus für kontinuierliche Aktions- und Zustandsräume
- Wird in zwei Veröffentlichungen beschrieben:
 - Soft Actor-Critic: Off-Policy Maximum Entropy Deep Reinforcement Learning with a Stochastic Actor
 - Soft Actor-Critic Algorithms and Applications
- Besitzt Ähnlichkeiten zu DDPG und TD3

Deep Deterministic Policy Gradient (DDPG)

- Basiert auf Deep Q-Networks
- Approximiert mit einem Neuronalen Netz eine Q-Function
- Für eine höhere Stabilität wird ein Target Netzwerk genutzt
- Nutzt für die Aktionsauswahl einen Actor-Critic Ansatz

Actor-Critic

- Soft Actor Critic nutzt einen Actor-Critic Ansatz
- Actor lernt eine Policy
- Critic lernt eine Value Function



Twin-Delayed DDPG (TD3)

- Weiterentwicklung von DDPG
- Nutzt zwei Netze für die Schätzung der Q-Values
- Q-Value Netze werden öfter upgedatet als andere Netze
- Fügt noise zu den target actions hinzu

Soft Actor-Critic

- Im Gegensatz zu DDPG und TD3 nutzt Soft Actor-Critic eine stochastische Policy
- Durch den off-policy Ansatz besitzt Soft Actor-Critic eine hohe Probeneffizienz
- Die Stabilität kann im Vergleich zu DDPG und TD3 erhöht werden

Maximierung der Entropie

- Standard Reinforcement Learning maximiert die Belohnung

$$\sum_{t=0}^T \mathbb{E}_{(s_t, a_t) \sim \rho_\pi} [r(s_t, a_t)]$$

- Soft Actor-Critic maximiert zusätzlich noch die Entropie

$$\sum_{t=0}^T \mathbb{E}_{(s_t, a_t) \sim \rho_\pi} [r(s_t, a_t) + \alpha \mathcal{H}(\pi(\cdot | s_t))]$$

- Parameter α kann fest gesetzt werden oder mittels gradient descent angepasst werden

Entropie

- Niedrige Entropie entspricht der Wahl einer festen Aktion
- Durch die Maximierung der Entropie haben Aktionen mit ähnlichen Q-Values eine ähnlich Wahrscheinlichkeit ausgewählt zu werden
- Die ausgewählte Aktion ist damit möglichst zufällig

Soft Policy Iteration

- Soft Policy Iteration ist die Basis für Soft Actor-Critic
- Benötigt Problem in tabellarischer Form
- Evaluiert und verbessert abwechselnd die Policy

Policy Evaluation

- Q-Values werden iterativ durch die Anwendung eines modifizierten Bellman backup operators \mathcal{T}^π berechnet

$$\mathcal{T}^\pi Q(s_t, a_t) \triangleq r(s_T, a_t) + \gamma \mathbb{E}_{s_{t+1} \sim p}[V(s_{t+1})]$$

$$V(s_t) = \mathbb{E}_{a_t \sim \pi}[Q(s_t, a_t) - \alpha \log \pi(a_t | s_t)]$$

- Durch wiederholte Ausführung des Operators kann die Q-Function einer Policy π berechnet werden

Policy Improvement

- Policy wird an die neue Q-Funktion angepasst
- Mit Hilfe der Kullback-Leibler Divergenz wird die Policy auf eine gaußsche Verteilung projiziert

$$\pi_{\text{new}} = \arg \min_{\pi' \in \Pi} D_{\text{KL}} \left(\pi'(\cdot | s_t) \parallel \frac{\exp(\frac{1}{\alpha} Q^{\pi_{\text{old}}}(s_t, \cdot))}{Z^{\pi_{\text{old}}}(s_t)} \right)$$

Inhaltsverzeichnis

1 Soft Actor-Critic Grundlagen

- Motivation
- Soft Policy Iteration

2 Soft Actor-Critic im kontinuierlichen Raum

- SAC Grundprinzip
- SAC Update Regeln
- Algorithmus

3 Ergebnisse

- Vergleich mit anderen Algorithmen
- Zusammenfassung

4 Literaturverzeichnis

Kontinuierlicher Aktionsraum

- große kontinuierliche Aktionsräume
 - ⇒ Approximation der Soft Policy Iteration
- Schritt von Tabellen zu DNNs
- Optimierung mittels gradient descent

Funktionen und deren Netzwerke

- Q-Function:

$Q_\theta(s_t, a_t) \rightarrow$ Q-Value als Ausgabe

- Policy:

$\pi_\phi(s_t | a_t) \rightarrow$ Mittelwert und Kovarianz als Ausgabe \Rightarrow Gauss

Mit Parametervektoren θ und ϕ

Value Function

- benötigt für Q-Function
- eigenes Netzwerk für Value-Function kann
 - Training stabilisieren
 - simultanes Training aller Netzwerke möglich machen
- hier: kein eigenes Value Netzwerk
- Berechnung über Value-Function aus Soft Policy Iteration

$$V(s_t) = \mathbb{E}_{a_t \sim \pi}[Q(s_t, a_t) - \alpha \log \pi(a_t | s_t)]$$

Optimierung Q-Funktion

- Minimierung des Fehlers
- Fehlerfunktion: soft Bellman residual

$$J_Q(\theta) = \mathbb{E}_{(s_t, a_t) \sim D} \left[\frac{1}{2} (Q_\theta(s_t, a_t) - (r(s_t, a_t) + \gamma \mathbb{E}_{s_{t+1} \sim p}[V_{\bar{\theta}}(s_{t+1})]))^2 \right]$$

mit parametrisierter Value-Function $V_{\bar{\theta}}$

- Training über gradient descent

Optimierung der Strategie

- Minimierung des Fehlers
- Fehlerfunktion: KL-Divergenz

$$J_{\pi}(\phi) = \mathbb{E}_{s_t \sim D} [\mathbb{E}_{a_t \sim \pi_{\phi}} [\alpha \log(\pi_{\phi}(a_t | s_t)) - Q_{\theta}(s_t, a_t)]]$$

- für vereinfachtes Training: reparameterization trick

Reparameterization trick

- Ziel: stochastisches Netzwerk \Rightarrow deterministisches Netzwerk
 \Rightarrow einfachere Gradientenberechnung und Training
- f_ϕ : vektorwertige Abbildung auf Aktionsraum, mit Parameter ϕ
- ϵ : noise Vektor, aus fixer Verteilungsfunktion, z.B. Gauss

$$a_t = f_\phi(\epsilon_t; s_t)$$

$$J_\pi(\phi) = \mathbb{E}_{s_t \sim D, \epsilon_t \sim N} [\alpha \log \pi_\phi(f_\phi(\epsilon_t; s_t) | s_t) - Q_\theta(s_t, f_\phi(\epsilon_t; s_t))]$$

- Training über gradient descent

α -Training

- passenden temperature Wert α zu finden ist schwer
- Entropie verändert sich, je genauer die policy wird
 - ⇒ optimale Aktion unklar: mehr exploration
 - ⇒ optimale Aktion klar: mehr exploitation
- Lösung: α wird über gradient descent trainiert
- Fehlerfunktion für α :

$$J(\alpha) = \mathbb{E}_{a_t \sim \pi_t} [-\alpha \log \pi_t(a_t | s_t) - \alpha \mathcal{H}]$$

Algorithmus (1/2)

- Benutzung zweier Q-Funktionen
- Training zweier Parameter θ_1 und θ_2
- Gradientenberechnung mit $\min\{Q_{\theta_1}, Q_{\theta_2}\}$
 - ⇒ verhindert starke Überschätzung des Q-Wertes
 - ⇒ bessere Performance
- target Q-Netzwerke werden angepasst

Algorithmus (2/2)

Algorithm 1: Soft Actor-Critic

Input θ_1, θ_2, ϕ

$\bar{\theta}_1 \leftarrow \theta_1, \bar{\theta}_2 \leftarrow \theta_2, \mathcal{D} \leftarrow \emptyset$

for each iteration do

for each environment step do

$a_t \sim \pi_\phi(a_t | s_t), s_{t+1} \sim p(s_{t+1} | s_t, a_t)$
 $D \leftarrow D \cup \{(s_t, a_t, r(s_t, a_t), s_{t+1})\}$

end

for each gradient step do

$\theta_i \leftarrow \theta_i - \lambda_Q \hat{\nabla}_{\theta_i} J_Q(\theta_i) \text{ for } i \in \{1, 2\}$
 $\phi \leftarrow \phi - \lambda_\pi \hat{\nabla}_\phi J_\pi(\phi)$
 $\alpha \leftarrow \alpha - \lambda \hat{\nabla}_\alpha J(\alpha)$
 $\bar{\theta}_i \leftarrow \tau \theta_i + (1 - \tau) \bar{\theta}_i \text{ for } i \in \{1, 2\}$

end

end

Inhaltsverzeichnis

1 Soft Actor-Critic Grundlagen

- Motivation
- Soft Policy Iteration

2 Soft Actor-Critic im kontinuierlichen Raum

- SAC Grundprinzip
- SAC Update Regeln
- Algorithmus

3 Ergebnisse

- Vergleich mit anderen Algorithmen
- Zusammenfassung

4 Literaturverzeichnis

Ziel der Experimente

- Stabilität und Sample Komplexität im Vergleich zu anderen Algorithmen
 - Kontinuierliche Aufgaben
 - Verschiedene Schwierigkeitgrade
- OpenAI gym und rllab

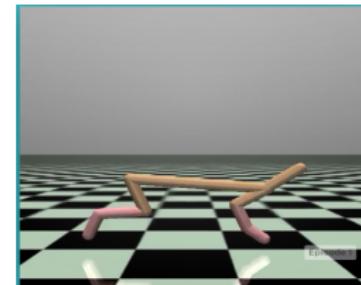
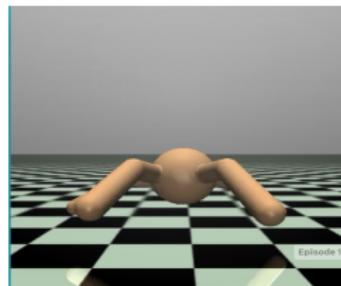
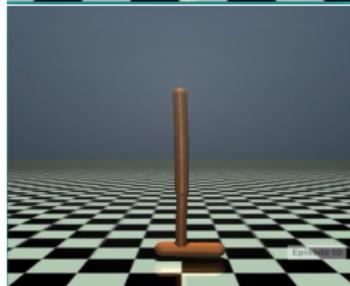
Vergleich zu anderen Algorithmen

- SAC
 - Durchschnittswert (mean action)
 - Feste und variable Temperatur (Anpassung im neuen Paper)
- PPO, DDPG
 - Kein Exploration noise
- TD3
- SQL mit zwei Q Funktionen
 - Evaluation mit Exploration noise

Vergleich zu anderen Algorithmen

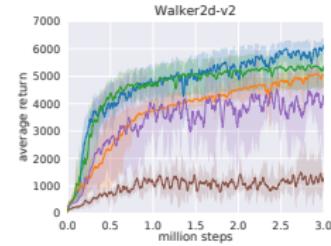
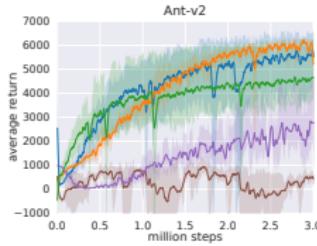
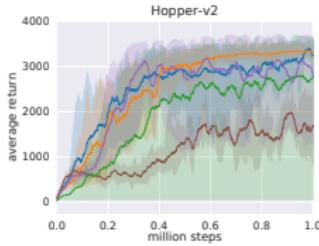
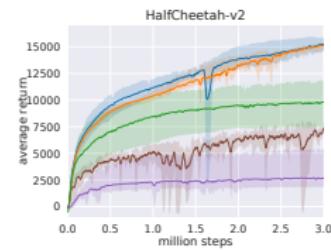
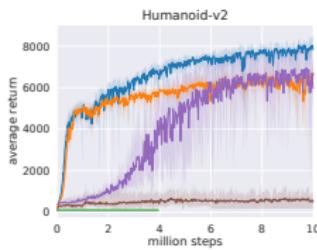
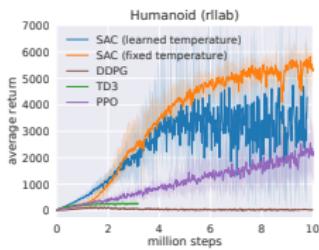
- 5 Instanzen mit einer Evaluation alle 1000 Schritte
- Schattierter Verlauf zeigt min und max der fünf Durchläufe

Ergebnisse



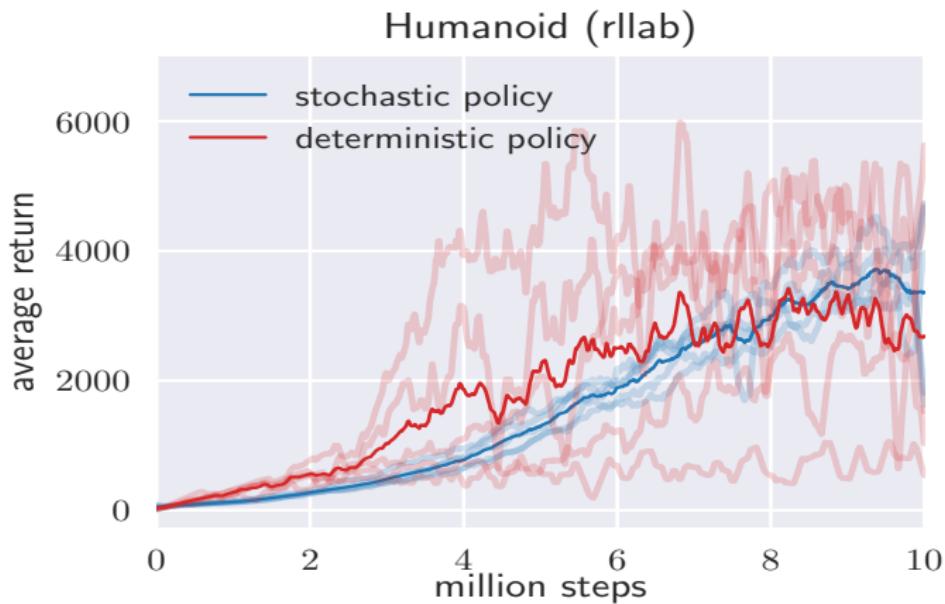
[AI]

Ergebnisse



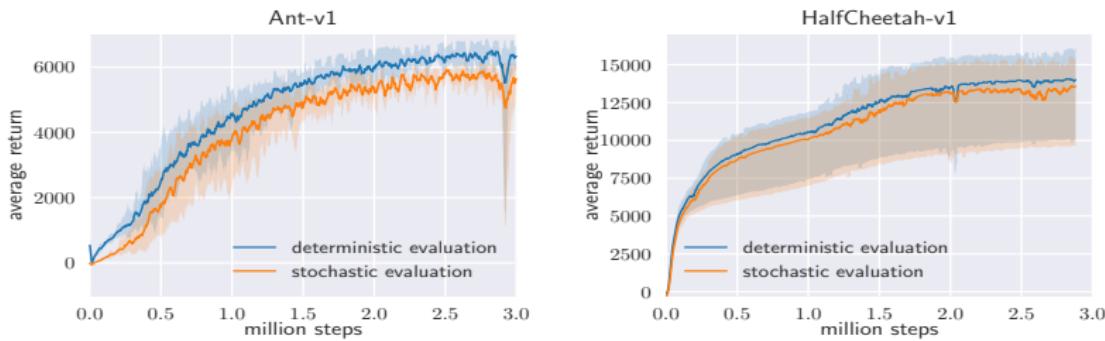
[HZH⁺18]

Deterministisch vs Stochastisch



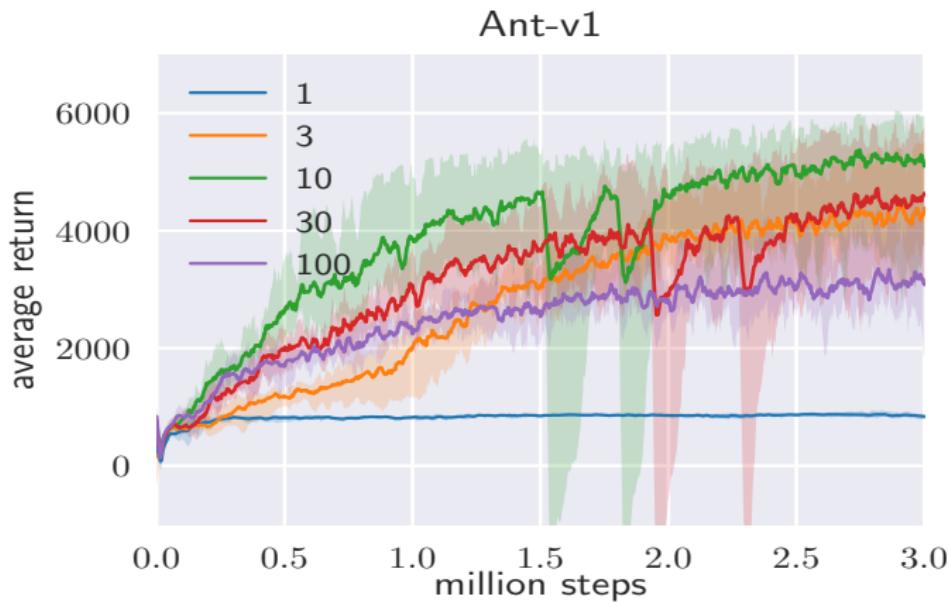
[HZAL18]

Deterministische Evaluation



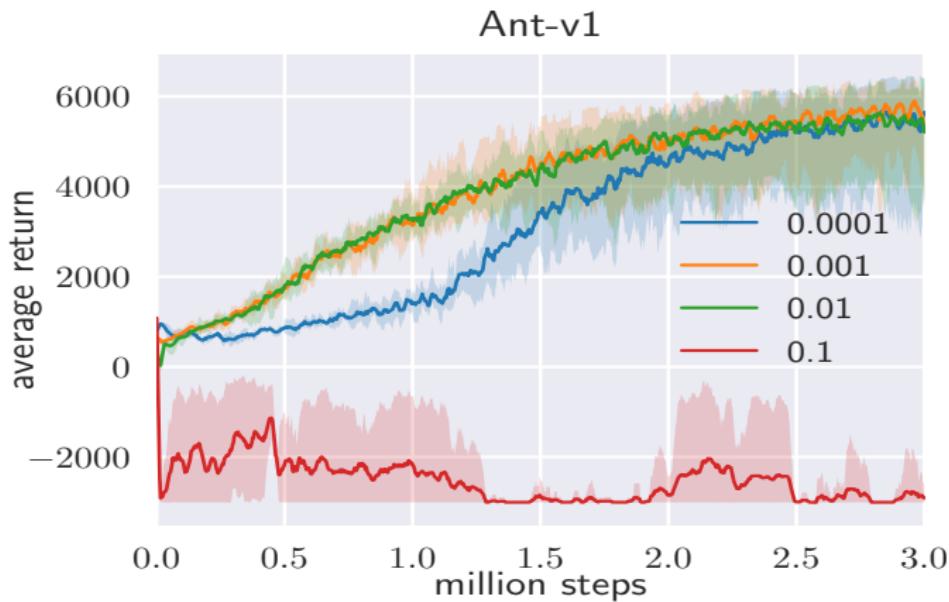
[HZAL18]

Reward Scale



[HZAL18]

Target Network Update



[HZAL18]

Zusammenfassung

- Soft actor critic vorgestellt
 - Off policy Algorithmus
 - Entropimaximierung verbessert Stabilität
 - temperature Wert wird gelernt statt fest zu setzen
- Experimente in verschiedenen Umgebungen
- Besser als state-of-the-art Algorithmen
- Stabiler als state-of-the-art Algorithmen

**Open AI.**

Open ai environments.

**Scott Fujimoto, Herke van Hoof, and David Meger.**

Addressing function approximation error in actor-critic methods.

CoRR, abs/1802.09477, 2018.**Tuomas Haarnoja, Aurick Zhou, Pieter Abbeel, and Sergey Levine.**

Soft actor-critic: Off-policy maximum entropy deep reinforcement learning with a stochastic actor.

CoRR, abs/1801.01290, 2018.**Tuomas Haarnoja, Aurick Zhou, Kristian Hartikainen, George Tucker, Sehoon Ha, Jie Tan, Vikash Kumar, Henry****Zhu, Abhishek Gupta, Pieter Abbeel, and Sergey Levine.**

Soft actor-critic algorithms and applications.

CoRR, abs/1812.05905, 2018.**Diederik P Kingma and Max Welling.**

Auto-encoding variational bayes, 2014.

**Richard S. Sutton and Andrew G. Barto.***Reinforcement Learning: An Introduction.*

1998.

**Andrew Trask.***Grokkling Deep Learning.*

Manning Publications Co., USA, 1st edition, 2019.